

Empirical Evaluation of Chunking Strategies for RAG over Structured Technical Documentation

Trần Mai Thảo Nhi
240104049

Đào Bình Minh
240104041

Trường Đại học Công nghệ Thông tin, ĐHQG-HCM
Giảng viên hướng dẫn: TS. Nguyễn Văn Kiệt

Abstract

Chunking ảnh hưởng trực tiếp đến khả năng truy xuất bằng chứng và chất lượng câu trả lời trong hệ thống *Retrieval-Augmented Generation* (RAG). Nghiên cứu này so sánh ba chiến lược *fixed-size*, *structure-aware* và *prompt-based* trên 384 tài liệu kỹ thuật Angular ở định dạng Markdown. Nhóm đồng thời xây dựng một bộ benchmark gồm 140 câu hỏi gắn với bằng chứng nguồn và đánh giá các chiến lược trong cùng một pipeline được kiểm soát. Kết quả cho thấy *fixed-size* phù hợp hơn khi ưu tiên thứ hạng truy xuất và chất lượng câu trả lời, trong khi *structure-aware* có lợi thế về khả năng thu hồi đầy đủ bằng chứng. *Prompt-based* chưa thể hiện ưu thế nhất quán. Đáng chú ý, khả năng thu hồi bằng chứng tốt hơn không nhất thiết chuyển thành chất lượng câu trả lời cao hơn. Vì vậy, chiến lược chunking cần được lựa chọn theo mục tiêu của hệ thống RAG thay vì dựa trên một chỉ số duy nhất.

1 Giới thiệu

Retrieval-Augmented Generation (RAG) cải thiện khả năng trả lời của Large Language Models bằng cách bổ sung thông tin được retrieval từ nguồn dữ liệu bên ngoài (?). Trong RAG pipeline, chunking chia tài liệu thành các đơn vị dùng cho embedding, indexing và retrieval. Ranh giới chunk không phù hợp có thể làm phân tán evidence hoặc gộp các nội dung không cùng ngữ nghĩa, từ đó ảnh hưởng đến retrieval performance và answer quality.

Vấn đề này đặc biệt quan trọng đối với technical documentation ở định dạng Markdown. Các thành phần như heading, section, paragraph, list, table và code block tạo thành cấu trúc phân cấp thay vì một chuỗi văn bản phẳng. Fixed-size chunking đơn giản nhưng có thể cắt qua section boundary. Structure-aware chunking bảo toàn cấu trúc tài liệu, trong khi prompt-based chunking sử dụng

Large Language Model để đề xuất chunk boundary dựa trên nội dung. Tuy nhiên, chưa rõ việc bảo toàn cấu trúc có đồng thời cải thiện retrieval ranking, evidence recovery và downstream answer quality hay không.

Nghiên cứu này thực hiện controlled comparison giữa fixed-size, structure-aware và prompt-based chunking trên 384 tài liệu Angular Markdown. Để cô lập ảnh hưởng của chunking strategy, các thành phần còn lại của pipeline, gồm embedding model, dense retriever, retrieval budget, context construction, answer generator và evaluator, được giữ cố định. Nghiên cứu tập trung vào ba research questions:

- RQ1.** Chunking strategy ảnh hưởng như thế nào đến retrieval ranking?
- RQ2.** Structure preservation có cải thiện khả năng retrieval đầy đủ gold evidence không?
- RQ3.** Retrieval và evidence recovery tốt hơn có chuyển thành downstream answer quality cao hơn không?

Để đánh giá các research questions, chúng tôi xây dựng một evidence-grounded QA benchmark gồm 140 câu hỏi và 233 evidence items, bao phủ single-section, cross-section và cross-document questions. Benchmark được tạo với sự hỗ trợ của ChatGPT và được ba software engineers lần lượt review và chỉnh sửa.

Kết quả cho thấy fixed-size đạt kết quả tốt hơn về early ranking và Token F1, trong khi structure-aware đạt evidence coverage và all-evidence-retrieved rate cao hơn. Prompt-based chưa thể hiện ưu thế nhất quán. Evidence recovery tốt hơn cũng không tự động chuyển thành answer quality cao hơn, cho thấy chunking cần được đánh giá trên nhiều tầng thay vì chỉ dựa vào một retrieval metric.

Các đóng góp chính của nghiên cứu gồm:

1. So sánh có kiểm soát ba chunking strategies trên structured Markdown documentation.
2. Xây dựng evidence-grounded QA benchmark cho technical documentation.
3. Đánh giá tác động của chunking trên ba tầng gồm retrieval ranking, evidence recovery và answer quality.

2 Related Work

2.1 Chunking Strategies

Chunking quyết định đơn vị văn bản được embedding và truy xuất trong hệ thống RAG (Lewis et al., 2020). Các phương pháp hiện có có thể được phân thành năm nhóm chính.

Fixed-size chunking. Phương pháp này chia văn bản thành các cửa sổ cố số token hoặc ký tự cố định, thường kèm overlap để giảm mất thông tin tại ranh giới. Fixed-size dễ triển khai và kiểm soát chi phí, nhưng không xét đến cấu trúc hoặc tính liên kết ngữ nghĩa của nội dung (Qu et al., 2025).

Sentence- and paragraph-based chunking. Nhóm phương pháp này sử dụng câu hoặc đoạn văn làm ranh giới tự nhiên. Cách tiếp cận này hạn chế việc cắt giữa câu nhưng có thể tạo ra các chunk có kích thước không đồng đều hoặc tách rời những phần nội dung phụ thuộc lẫn nhau (Qu et al., 2025).

Semantic chunking. Semantic chunking xác định ranh giới dựa trên mức độ tương đồng embedding giữa các câu liên tiếp. Mục tiêu là duy trì tính liên kết ngữ nghĩa, nhưng phương pháp này làm tăng chi phí xử lý và chưa cho thấy lợi ích nhất quán so với fixed-size chunking (Qu et al., 2025).

Structure-aware chunking. Structure-aware chunking khai thác heading hierarchy, paragraph, list, table, code block hoặc abstract syntax tree (AST). Các thành phần có quan hệ được tổ chức theo cấu trúc phân cấp nhằm bảo toàn ngữ cảnh của tài liệu (Jain et al., 2025).

LLM-assisted chunking. LLM-assisted hoặc prompt-based chunking sử dụng language model để xác định các đơn vị nội dung và đề xuất ranh giới linh hoạt. Các phương pháp như PIC và AutoChunker cho thấy khả năng kết hợp tin hiệu ngữ nghĩa với cấu trúc tài liệu, nhưng yêu cầu thêm chi phí suy luận và cơ chế kiểm soát đầu ra (Wang et al., 2025; Jain et al., 2025).

2.2 Evaluation of RAG Systems

Đánh giá RAG thường được thực hiện ở nhiều cấp độ (Yu et al., 2024). Ở cấp retrieval, Hit@K, Recall@K và Mean Reciprocal Rank (MRR) đo khả năng truy xuất và xếp hạng nguồn liên quan. Ở cấp evidence, Evidence Coverage và All-Evidence-Retrieved Rate phản ánh mức độ thu hồi các bằng chứng cần thiết. Ở cấp câu trả lời, các chỉ số như Token F1, BLEU và ROUGE đo mức độ tương đồng với đáp án tham chiếu; human evaluation có thể bổ sung đánh giá về tính chính xác và đầy đủ. Việc phân biệt ba cấp độ là cần thiết vì cải thiện retrieval hoặc evidence recovery không nhất thiết dẫn đến chất lượng câu trả lời cao hơn (Qu et al., 2025).

2.3 Research Gap

Các nghiên cứu gần đây đã so sánh fixed-size với semantic chunking hoặc đề xuất phương pháp phân đoạn mới (Qu et al., 2025; Wang et al., 2025). Tuy nhiên, tác động của việc bảo toàn cấu trúc tài liệu đến retrieval ranking, evidence recovery và answer quality vẫn chưa được đánh giá đầy đủ trong cùng một thiết lập trên tài liệu kỹ thuật có cấu trúc. Nghiên cứu này giải quyết khoảng trống đó bằng cách so sánh fixed-size, structure-aware và prompt-based chunking trong một pipeline được kiểm soát, đồng thời đánh giá riêng biệt cả ba cấp độ.

3 Corpus and QA Benchmark

3.1 Technical Document Corpus

Corpus gồm 384 tài liệu kỹ thuật Angular ở định dạng Markdown. Các tài liệu có cấu trúc phân cấp thông qua heading và chứa nhiều loại block như paragraph, list, table, code block và callout. Đặc điểm này cho phép đánh giá ảnh hưởng của việc bảo toàn cấu trúc tài liệu trong quá trình chunking.

Trong bước tiền xử lý, mỗi tài liệu được phân tích thành chuỗi block theo thứ tự xuất hiện trong nguồn. Đối với mỗi block, hệ thống lưu loại nội dung, văn bản gốc và đường dẫn heading tương ứng. Nội dung không được tóm tắt hoặc viết lại nhằm bảo toàn bằng chứng nguồn cho quá trình đánh giá.

3.2 QA Benchmark Construction

Do chưa có benchmark phù hợp trực tiếp với corpus và mục tiêu nghiên cứu, nhóm xây dựng một bộ câu hỏi–trả lời có gắn bằng chứng nguồn. ChatGPT được sử dụng để hỗ trợ tạo câu hỏi ứng viên,

Độ khó	Số câu	Tỷ lệ
Easy	60	42.9%
Medium	40	28.6%
Hard	40	28.6%
Tổng	140	100.0%

Table 1: Phân bố câu hỏi theo độ khó.

đáp án tham chiếu và vùng bằng chứng ban đầu. Các đầu ra này chỉ được xem là bản nháp và không được đưa trực tiếp vào benchmark cuối cùng.

Mỗi mẫu sau đó trải qua *sequential expert review* bởi ba kỹ sư phần mềm có từ bốn đến năm năm kinh nghiệm. Các chuyên gia lần lượt kiểm tra và chỉnh sửa câu hỏi, đáp án, loại câu hỏi, kiểu suy luận, độ khó và bằng chứng nguồn. Một mẫu chỉ được chấp nhận khi có thể trả lời đầy đủ từ corpus và không phụ thuộc vào kiến thức bên ngoài.

3.3 Data Structure and Chunk-Neutral Ground Truth

Mỗi QA record gồm các trường chính sau:

- question_id: mã định danh của câu hỏi;
- question: nội dung câu hỏi;
- reference_answer: đáp án tham chiếu;
- difficulty: mức độ easy, medium hoặc hard;
- question_type: loại câu hỏi;
- reasoning_type: kiểu suy luận cần thiết;
- evidence: danh sách các evidence item.

Mỗi evidence item lưu mã bằng chứng, mã tài liệu, đường dẫn section và các câu chứa bằng chứng. Ground truth được liên kết với nội dung tài liệu gốc thay vì chunk được tạo bởi một phương pháp cụ thể. Benchmark không lưu chunk_id, relevant_chunk_id hoặc nhãn phụ thuộc vào chiến lược chunking. Nguyên tắc này cho phép cùng một ground truth được sử dụng công bằng cho fixed-size, structure-aware và prompt-based chunking.

3.4 Benchmark Statistics

Benchmark cuối cùng gồm 140 câu hỏi và 233 evidence items. Phân bố theo độ khó được trình bày trong Bảng 1.

Các câu hỏi còn được phân loại theo phạm vi bằng chứng. *Single-section* sử dụng bằng chứng trong một section; *cross-section* kết hợp nhiều section trong cùng tài liệu; và *cross-document* yêu cầu

Phạm vi bằng chứng	Số câu
Single-section	50
Cross-section	60
Cross-document	30
Tổng	140

Table 2: Phân bố câu hỏi theo phạm vi bằng chứng.

bằng chứng từ nhiều tài liệu. Phân bố tương ứng được trình bày trong Bảng 2.

3.5 Difficulty Design

Độ khó được xác định dựa trên số vùng bằng chứng, độ phức tạp suy luận, mức độ phụ thuộc giữa các phần tài liệu và phạm vi thông tin cần bao phủ. Tất cả câu hỏi đều phải có đủ bằng chứng trong corpus; nhãn hard không biểu thị câu hỏi mơ hồ hoặc thiếu thông tin.

Câu hỏi easy chủ yếu thuộc nhóm fact hoặc definition và dựa trên một vùng bằng chứng cục bộ. Câu hỏi medium yêu cầu kết hợp hai evidence items, thường thuộc các nhóm comparison, procedure, cause–effect hoặc multi-fact synthesis. Trong 40 câu medium, 27 câu có hai evidence items trong cùng một section và 13 câu sử dụng bằng chứng từ nhiều section. Câu hỏi hard kết hợp từ hai đến ba vùng bằng chứng và có thể yêu cầu tổng hợp, phân tích trade-off, theo dõi thay đổi trạng thái hoặc đối chiếu thông tin phân tán.

4 Chunking Strategies

Nghiên cứu so sánh ba chiến lược chunking trên cùng corpus. Mỗi chiến lược tạo một tập chunk độc lập, trong đó kích thước mỗi chunk không vượt quá 512 token.

4.1 Fixed-size Chunking

Fixed-size tuyến tính hóa tài liệu theo thứ tự nguồn và chia văn bản thành các cửa sổ 512 token, với 64 token overlap giữa hai cửa sổ liên tiếp. Phương pháp không sử dụng heading hoặc cấu trúc phân cấp khi xác định ranh giới. Kết quả tạo ra 1,300 chunks và được lưu thành artifact fixed_size_v1.

4.2 Structure-aware Chunking

Structure-aware sử dụng heading hierarchy của Markdown và giữ lại đường dẫn heading cho từng chunk. Nội dung được đóng gói theo từng section, không gộp các sibling section và không sử dụng overlap.

Khi một đơn vị nội dung vượt quá 512 token, paragraph được chia theo câu, code block theo dòng, list theo item và table theo hàng. Phương pháp tạo ra 3,162 chunks và được lưu thành artifact structure_aware_v1.

4.3 Prompt-based Chunking

Prompt-based biểu diễn tài liệu dưới dạng chuỗi block có thứ tự và sử dụng language model để đề xuất các khoảng block liên tục làm ranh giới chunk. Mô hình chỉ xác định ranh giới, không tóm tắt hoặc viết lại nội dung.

Các đề xuất được local code kiểm tra về độ bao phủ, thứ tự, provenance và giới hạn 512 token trước khi tạo chunk. Phương pháp tạo ra 2,054 chunks và được lưu thành artifact prompt_based_v1.

Ba artifact trên được chuyển trực tiếp vào cùng một embedding, retrieval và answer generation pipeline. Phần tiếp theo trình bày cách kiểm soát các thành phần này để chiến lược chunking là biến độc lập duy nhất trong thực nghiệm.

5 Thiết lập Thực nghiệm

Để đánh giá chính xác và khách quan tác động của cấu trúc tài liệu lên hiệu năng của hệ thống RAG (Retrieval-Augmented Generation), chúng tôi thiết lập một khuôn khổ thực nghiệm có kiểm soát, hệ thống tiếp nhận ba tập chunk artifact chuẩn hóa từ giai đoạn tiền xử lý: fixed_size, structure_aware và prompt_based. Phần này trình bày chi tiết về kiến trúc pipeline có kiểm soát, retrieval protocol với token budget, cấu hình mô hình generation, các evaluation metrics đa tầng và quy trình audit dữ liệu đảm bảo tính tái lập tuyệt đối.

5.1 Controlled Pipeline Architecture

Nguyên tắc cốt lõi của thiết kế thực nghiệm là *single independent variable*: Chiến lược chunking (Fixed-size, Structure-aware, hoặc Prompt-based) là biến độc lập duy nhất được phép thay đổi. Tất cả các thành phần còn lại trong chu trình RAG đều được cố định 100% và đóng băng tuyệt đối, bao gồm cùng một tập tài liệu nguồn (384 tài liệu kỹ thuật Markdown của Angular), cùng embedding model và vector index, cùng không gian biểu diễn vector, cùng retrieval protocol với token budget cố định, cùng context builder, cùng mô hình generator với tham số giải mã tắt định, và cùng bộ metrics đánh giá tự động.

Như được minh họa trực quan trong Figure 1,

toàn bộ pipeline có kiểm soát được tổ chức chặt chẽ thành 5 giai đoạn liên hoàn:

1. **Giai đoạn 1 – Xử lý tài liệu:** Bắt đầu từ kho ngữ liệu gồm 384 tài liệu kỹ thuật Angular định dạng Markdown. Tài liệu được làm sạch và chuẩn hóa cấu trúc thông qua bước tiền xử lý, sau đó phân đoạn theo ba chiến lược chunking độc lập:

- *Fixed-size*: Cửa sổ cố định 512 tokens với overlap 64 tokens.
- *Structure-aware*: Phân đoạn theo AST, tôn trọng ranh giới section và khối nguyên tử với kích thước tối đa 512 tokens.
- *Prompt-based*: Sử dụng LLM đề xuất ranh giới ngữ nghĩa và kiểm tra bất biến cục bộ.

Kết quả của cả ba nhánh được xuất xưởng thành các Unified Chunk Artifacts ở cùng một schema chuẩn hóa, lưu vết đầy đủ meta-data và số lượng token (token_count).

2. **Giai đoạn 2 – Tạo chỉ mục (Indexing):**

Toàn bộ các chunk được chuyển thành vector embedding thông qua mô hình text-embedding-3-small với không gian 1.536 chiều, sử dụng chung một cấu hình duy nhất cho tất cả các chiến lược. Các vector này sau đó được nạp vào chỉ mục vector cục bộ (local_cosine_index) với cơ chế giải quyết xung đột thứ hạng có tính tắt định.

3. **Giai đoạn 3 – Xử lý truy vấn & Truy xuất (Retrieval):**

Bộ câu hỏi gồm 140 câu hỏi benchmark được chuyển đổi thành query embedding bằng chính mô hình nhúng ở Giai đoạn 2. Bộ truy xuất tính toán Cosine Similarity để trích xuất 50 ứng viên tiềm năng ban đầu (Candidate Pool). Tiếp đó, cơ chế lựa chọn kết quả áp dụng thuật toán tích lũy tham lam để chọn lọc các chunk nguyên khối thỏa mãn trần token budget (2.048 tokens).

4. **Giai đoạn 4 – Tạo câu trả lời (Generation):**

Các chunk được lựa chọn nạp vào bước xây dựng ngữ cảnh (context assembly) theo quy trình chuẩn hóa cố định. Khối ngữ cảnh hoàn chỉnh được đưa vào prompt template cùng chỉ dẫn hệ thống nghiêm ngặt. Generator sử dụng mô hình gpt-5-mini với chế độ greedy decoding (temperature = 0) để sinh câu trả lời kỹ thuật có tính tắt định cao.




Figure 1: Kiến trúc Controlled Pipeline tổng thể: (1) Xử lý tài liệu và phân đoạn với ba chunking strategies; (2) Tạo embedding và vector index; (3) Xử lý 140 truy vấn, retrieval theo Cosine Similarity và lựa chọn kết quả theo token budget; (4) Xây dựng ngữ cảnh và sinh câu trả lời bằng GPT-5-mini (temperature = 0); (5) Đánh giá đa chiều retrieval metrics và answer quality.

5. Giai đoạn 5 – Đánh giá (Evaluation): Đánh giá đa chiều và phân tích thống kê độc lập trên hai phương diện chính:

- **Retrieval metrics:** Đánh giá khả năng xếp hạng và độ thu hồi bằng chứng (Hit@K, MRR, Recall@10, Evidence Coverage, AER).
- **Answer quality:** Đánh giá độ chuẩn xác từ vựng của câu trả lời sinh ra so với nhãn chuẩn của chuyên gia (Token Precision, Token Recall, Token F1).

5.2 Retrieval Protocol và Token Budget

Để loại bỏ các sai số hệ thống do sự chênh lệch về kích thước khối văn bản giữa các phương pháp chunking, retrieval protocol được thiết kế nhằm đảm bảo sự công bằng tuyệt đối về dung lượng thông tin nạp vào mô hình sinh.

Embedding Model và Độ đo Tương đồng. Hệ thống sử dụng mô hình nhúng text-embedding-3-small của OpenAI, biểu diễn văn bản dưới dạng các vector thực 1.536 chiều với định dạng số thực (float). Tokenizer chuẩn hóa là cl100k_base, hỗ trợ ngữ cảnh đầu vào tối đa 8.192 tokens. Mỗi câu truy vấn trước hết được chuẩn hóa khoảng trắng tối thiểu (trim-only), sau đó nhúng thành vector truy vấn $\mathbf{q} \in \mathbb{R}^{1536}$. Độ tương đồng giữa vector

truy vấn $\mathbf{q}$ và vector chunk $\mathbf{d}$ được xác định bằng Cosine Similarity:

$$\text{CosineSimilarity}(\mathbf{q}, \mathbf{d}) = \frac{\mathbf{q} \cdot \mathbf{d}}{\|\mathbf{q}\|_2 \|\mathbf{d}\|_2} \quad (1)$$

Vector index được quản lý bởi backend local_cosine_jsonl (phiên bản schema local_cosine_index). Tie-breaking rule khi các chunk có cùng điểm số tương đồng được quy định chặt chẽ: ưu tiên điểm tương đồng giảm dần, trường hợp trùng điểm số sẽ đối chiếu thứ tự từ điển tăng dần của mã định danh chunk (score DESC, chunk_id ASC).

Candidate Pool. Với mỗi câu truy vấn, bộ dense retrieval ban đầu trích xuất một candidate pool gồm $k = 50$ chunks (candidate_k = 50) có Cosine Similarity cao nhất từ vector index.

Giao thức Token Budget. Thay vì cố định số lượng chunk trả về (Top- K)—vốn sẽ gây bất lợi bất công cho các phương pháp phân đoạn hạt mịn với kích thước khối nhỏ—chúng tôi áp dụng giao thức same_token_budget:

- **Trần ngân sách cố định:** Giới hạn ngân sách truy xuất được ấn định nghiêm ngặt ở mức $B = 2.048$ tokens.
- **Chính sách Tích lũy:** Áp dụng chính sách duyệt toàn khối và bỏ qua chunk quá khổ

(skip_nonfitting). Các ứng viên trong candidate pool gồm 50 chunks được duyệt tuần tự theo thứ tự điểm tương đồng giảm dần.

- **Bảo toàn Whole Chunks:** Hệ thống cam kết không bao giờ cắt xén văn bản dở dang (no partial truncation). Toàn bộ nội dung của chunk được giữ trọn vẹn. Số lượng token chỉ được tính toán trên phần thân văn bản thực tế của chunk thông qua giá trị token_count đã lưu vết bằng tiktoken:cl100k_base, hoàn toàn không bao gồm metadata hay separator.
- **Cơ chế Bỏ qua có Chọn lọc:** Nếu việc bổ sung chunk đang xét không vượt quá trần ngân sách ($T_{tích_lũy} + \text{len}(c) \leq B$), chunk đó sẽ được đưa vào danh sách lựa chọn và cập nhật ngân sách tích lũy. Ngược lại, nếu một chunk vượt quá dung lượng còn lại, hệ thống sẽ tạm thời bỏ qua (skip) chunk này và tiếp tục quét các ứng viên nhỏ hơn kế tiếp trong candidate pool cho đến khi tận dụng tối đa ngân sách 2.048 tokens hoặc duyệt hết tập ứng viên.
- **Xử lý Biên Ngoại lệ:** Nếu ngay chính chunk xếp hạng đầu tiên ($r = 1$) có kích thước vượt quá trần 2.048 tokens, nó sẽ được chấp nhận là phần tử đơn lẻ duy nhất và đánh dấu cờ cảnh báo vượt ngưỡng (budget_overflow = true). Trong tập dữ liệu thực tế, kích thước tối đa của các chunk ở cả ba chiến lược đều không vượt quá 512 tokens, do đó trường hợp ngoại lệ này không bao giờ bị kích hoạt.

5.3 Generation và Context Assembly

Giai đoạn sinh câu trả lời được cô lập hoàn toàn khỏi tầng truy xuất để đảm bảo tính độc lập và khả năng thẩm định lỗi cục bộ.

Context Assembly. Các chunk vượt qua giao thức token budget (2.048 tokens) được chuyển giao sang bộ dựng ngữ cảnh (AnswerPromptBuilder). Ngân sách ngữ cảnh tối đa nạp vào prompt được quy định ở mức 4.096 tokens (prepared_context_token_budget = 4096), nằm trong tổng context window 8.192 tokens của mô hình. Các chunk được ghép nối có cấu trúc theo prompt template chuẩn hóa (answer_prompt), giữ nguyên các tiền tố ngữ cảnh phân cấp tiêu đề để cung cấp căn cứ suy luận vững chắc cho mô hình ngôn ngữ.

Cấu hình Generator. Mô hình sinh câu trả lời chính thức là gpt-5-mini (truy xuất qua định danh API chuẩn openai/gpt-5-mini trên nền tảng OpenRouter). Cấu hình chi tiết gồm các tham số sau:

- **Nhiệt độ Giải mã (Temperature = 0.0):** Sử dụng chiến lược greedy decoding tuyệt đối. Việc triệt tiêu tính ngẫu nhiên giúp loại trừ phương sai lấy mẫu giữa các lần chạy, bảo đảm tính xác định và độ tái lập 100% cho mọi câu trả lời.
- **Mức độ Suy luận (Reasoning Effort):** Đặt ở mức low nhằm duy trì phản hồi nhanh, trực diện và hạn chế việc suy diễn chuỗi tư duy lan man ngoài phạm vi ngữ cảnh.
- **Giới hạn Token Đầu ra:** Thiết lập max_output_tokens = 1024, đủ rộng để chứa các câu trả lời kỹ thuật chi tiết kèm các đoạn mã nguồn minh họa nếu có.
- **Integrity Policy:** Áp dụng chính sách nonempty_text_require_stop_v2 với quy tắc bắt buộc require_stop. Mọi câu trả lời hợp lệ phải chứa văn bản không rỗng và kết thúc bình thường với lý do finish_reason = stop; mọi trường hợp ngắt do cạn token hoặc lỗi mạng đều bị từ chối và ghi vết lỗi.

Chiến lược Prompting. Hệ thống áp dụng Zero-shot QA với system prompt nghiêm ngặt phiên bản answer_system: Chiến lược này đặt ra yêu cầu tuyệt đối: mô hình chỉ được phép trả lời dựa trên những thông tin kỹ thuật được minh chứng trực tiếp trong các chunk được cung cấp, kiên quyết không ngoại suy hoặc bịa đặt dữ liệu (hallucination). Khi ngữ cảnh bị phân mảnh hoặc thiếu hụt bằng chứng, mô hình phải tuyên bố rõ ràng sự bất túc đó thay vì cố gắng tự tổng hợp từ tri thức tham số nội tại.

5.4 Evaluation Metrics

Để đánh giá toàn diện hiệu năng của hệ thống RAG từ pha truy xuất thông tin đến pha sinh ngôn ngữ, chúng tôi phân định rõ ràng ba nhóm chỉ số đo lường độc lập:

5.4.1 Retrieval và Ranking Metrics

Nhóm chỉ số này đo lường năng lực của bộ dense retrieval trong việc nhận diện và đẩy các nguồn tài liệu liên quan lên các vị trí xếp hạng đầu tiên trong danh sách ứng viên:

- **Hit@K** ($K \in \{1, 3, 5, 10\}$): Chỉ số nhị phân xác định xem có ít nhất một tài liệu nguồn liên quan thuộc tập chuẩn $\mathcal{D}_q^*$ xuất hiện trong Top- K kết quả trả về của câu hỏi q hay không:

$$\text{Hit@K} = \mathbb{I}(\exists r \leq K : d_r \in \mathcal{D}_q^*) \quad (2)$$

trong đó d_r là nguồn tài liệu ở thứ hạng r , và $\mathbb{I}(\cdot)$ là hàm chỉ thị.

- **Mean Reciprocal Rank (MRR)**: Đo lường độ nhạy của hệ thống đối với vị trí xuất hiện của tài liệu liên quan đầu tiên:

$$\text{MRR} = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{\text{rank}_i} \quad (3)$$

trong đó $\text{rank}_i = \min\{r \mid d_r \in \mathcal{D}_{q_i}^*\}$ là thứ hạng của tài liệu liên quan đầu tiên được tìm thấy cho câu hỏi q_i . Nếu không có tài liệu liên quan nào xuất hiện trong danh sách ứng viên, ta gán $1/\text{rank}_i = 0$.

- **Recall@10**: Tỷ lệ giữa số lượng tài liệu nguồn liên quan xuất hiện trong Top-10 so với tổng số tài liệu liên quan chuẩn của câu hỏi:

$$\text{Recall@10} = \frac{|\{d_r \mid r \leq 10\} \cap \mathcal{D}_q^*|}{|\mathcal{D}_q^*|} \quad (4)$$

5.4.2 Evidence Recovery Metrics

Trong các tác vụ hỏi đáp kỹ thuật, một câu hỏi có thể đòi hỏi nhiều bằng chứng độc lập nằm rải rác ở các phần khác nhau của tài liệu. Nhóm chỉ số này đánh giá khả năng của tập các chunk lọt vào token budget 2.048 tokens trong việc bảo toàn trọn vẹn 233 đơn vị bằng chứng chuẩn ($\mathcal{E}^*$):

- **Evidence Coverage**: Với mỗi đơn vị bằng chứng $e \in \mathcal{E}_q^*$ của câu hỏi q , hàm $\text{Cov}(e, \mathcal{C}_{\text{budget}}) \in [0, 1]$ biểu diễn tỷ lệ độ dài chuỗi ký tự của e xuất hiện trọn vẹn trong tập các chunk được lựa chọn $\mathcal{C}_{\text{budget}}$. Chỉ số Evidence Coverage vĩ mô là trung bình tỷ lệ bao phủ của toàn bộ các đơn vị bằng chứng trên tập câu hỏi Q :

$$\text{Coverage} = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{|\mathcal{E}_{q_i}^*|} \sum_{e \in \mathcal{E}_{q_i}^*} \text{Cov}(e, \mathcal{C}_{\text{budget}}) \quad (5)$$

- **All-Evidence-Retrieved Rate (AER)**: Thước đo nghiêm ngặt xác định tỷ lệ phần trăm các câu hỏi mà hệ thống thu hồi thành công 100% toàn bộ các đơn vị bằng chứng bắt buộc mà không làm thất thoát bất kỳ thành phần nào:

$$\text{AER} = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \prod_{e \in \mathcal{E}_{q_i}^*} \mathbb{I}(\text{Cov}(e, \mathcal{C}_{\text{budget}}) = 1.0) \quad (6)$$

5.4.3 Answer Generation Quality Metrics

Chất lượng câu trả lời sinh ra được đối chiếu với câu trả lời chuẩn mực của chuyên gia thông qua độ tương đồng từ vựng ở mức độ token:

- **Tiền xử lý và Tách từ Chuẩn hóa**: Cả câu trả lời dự đoán ($\hat{A}$) và câu trả lời tham chiếu chuẩn (A^*) đều trải qua quy trình chuẩn hóa Unicode NFKC, chuyển chữ thường (casefolding) và chuẩn hóa khoảng trắng (answer_normalization). Nhằm bảo toàn tính nguyên bản của cú pháp lập trình kỹ thuật (như tên phương thức, cú pháp lệnh hoặc tham số), các dấu câu được giữ nguyên, tuyệt đối không loại bỏ stopword hoặc áp dụng stemming/lemmatization. Văn bản sau đó được tách thành danh sách token thông qua biểu thức chính quy Unicode: $\backslash w + [\wedge \backslash w \backslash s]$.

- **Multiset Overlap**: Gọi $\hat{\mathcal{T}}$ và $\mathcal{T}^*$ lần lượt là multiset các token của câu trả lời dự đoán và câu trả lời chuẩn. Số lượng token trùng khớp được tính toán có xét đến số lần lặp:

$$\text{Overlap}(\hat{\mathcal{T}}, \mathcal{T}^*) = \sum_t \min(\text{count}_{\hat{\mathcal{T}}}(t), \text{count}_{\mathcal{T}^*}(t)) \quad (7)$$

- **Token Precision, Token Recall và Token F1**:

$$\text{Token P} = \frac{\text{Overlap}(\hat{\mathcal{T}}, \mathcal{T}^*)}{|\hat{\mathcal{T}}|} \quad (8)$$

$$\text{Token R} = \frac{\text{Overlap}(\hat{\mathcal{T}}, \mathcal{T}^*)}{|\mathcal{T}^*|} \quad (9)$$

Chỉ số Token F1 là trung bình điều hòa của Precision và Recall:

$$\text{Token F1} = \frac{2 \cdot \text{Token P} \cdot \text{Token R}}{\text{Token P} + \text{Token R}} \quad (10)$$

Điểm số cuối cùng của toàn hệ thống được tính bằng unweighted macro-average trên tất cả 140 câu hỏi trong tập benchmark.

5.5 Reproducibility và Protocol Audit

Để đảm bảo tính minh bạch khoa học và khả năng tái lập độc lập của công trình, toàn bộ quy trình thực nghiệm được đóng băng và kiểm toán nghiêm ngặt theo các tiêu chuẩn giao thức sau:

Benchmark Freeze Validation. Bộ dữ liệu đánh giá chính thức gồm 140 cặp câu hỏi – đáp án QA được cố định vĩnh viễn, phân bố đồng đều trên ba phân tầng độ khó: 60 câu Easy, 40 câu Medium và 40 câu Hard. Kèm theo đó là 233 đơn vị bằng chứng chuẩn (evidence items) được trích xuất trực tiếp từ các đoạn văn bản gốc. Tất cả các đơn vị bằng chứng này được thiết lập hoàn toàn độc lập với ranh giới phân đoạn của bất kỳ chiến lược chunking nào, ngăn ngừa triệt để hiện tượng thiên kiến dữ liệu (data leakage hoặc boundary tailoring).

Cryptographic Artifact Fingerprints. Nhằm bảo đảm tính toàn vẹn của chuỗi xuất xứ dữ liệu (provenance lineage), mọi cấu hình và tệp artifact trung gian trong toàn bộ pipeline đều được tính toán và neo giữ bằng mã băm SHA-256 định danh (canonical fingerprints):

- dataset_fingerprint: 9866799ea8f87c6a7c118cbaf0d8c298524757bd753db5d640e1a32234206d74.
- generation_fingerprint: c4f4768ec9b80361dfd0a1e252f74ff348aa4e4c953bcc02761ba345f38b301.
- evaluation_fingerprint: c6867bffb9d9775d3ef9b4ce666ae09f1995a6ccb7a7ef14858bbcd736c1fa55.
- retrieval_benchmark_fingerprint: 9dab4015ca1ae4c4abda04ccc5809a5e030c793fcc7feff932d04ecfb116a6b7.
- answer_benchmark_fingerprint: 375983ff4b3c4e84b303d7298c4dd93b44782430bbcf1fd6dff41db6f3b60af23.

Deterministic Execution Audit. Toàn bộ 420 lượt sinh câu trả lời (140 câu hỏi $\times$ 3 chiến lược phân đoạn) đều đạt tỷ lệ hoàn thành hợp lệ 100% với lý do kết thúc finish_reason = stop, không phát sinh bất kỳ trường hợp nào bị cắt ngắn do thiếu hụt context window, lỗi mạng hay phản hồi rỗng. Nhờ việc cố định tham số nhiệt độ Temperature = 0.0, khóa phiên bản mô hình,

chuẩn hóa bộ tách từ tiktoken và cố định tie-breaking rule, mọi thực nghiệm đều có khả năng tái lập tất định 100% (deterministic reproduction), đảm bảo kết quả thu được phản ánh thuần túy bản chất của các chiến lược phân đoạn cấu trúc.

6 Kết quả Thực nghiệm

Chương này trình bày các kết quả thực nghiệm thu được từ 420 lượt đánh giá câu trả lời đối sánh theo cặp trên 140 câu hỏi benchmark, tương ứng với ba chiến lược chunking: Fixed-size, Structure-aware và Prompt-based (sử dụng artifact đồng bộ bằng prompt_based_v1). Toàn bộ các phân tích định lượng dưới đây được trích xuất trực tiếp từ dữ liệu kiểm toán hệ thống, nhằm giải đáp tường minh ba câu hỏi nghiên cứu cốt lõi (RQs) và làm sáng tỏ các mối quan hệ trade-off trong chu trình RAG trên tài liệu kỹ thuật Markdown.

6.1 Tổng quan kết quả thực nghiệm (Main Experimental Results)

Bảng 3 tổng hợp toàn bộ hiệu năng của ba chiến lược trên ba phương diện chính: Retrieval & Ranking, Evidence Recovery và Answer Generation Quality dưới cùng một giới hạn retrieval token budget 2.048 tokens.

Kết quả tổng quan chỉ ra rằng không có bất kỳ chiến lược chunking đơn lẻ nào chiếm ưu thế tuyệt đối trên mọi chỉ số:

- **Fixed-size** dẫn đầu ở các chỉ số early ranking tại tầng retrieval với Hit@1 = 0.8071 và MRR = 0.8732, đồng thời đạt Token F1 = 0.3830 cao nhất ở đầu ra sinh câu trả lời downstream generation.
- **Structure-aware** áp đảo ở độ bao phủ bằng chứng và các thứ hạng sâu hơn, thiết lập hiệu năng vượt trội với Hit@10 = 1.0000, Recall@10 = 0.9857, Evidence Coverage = 0.7476 và All-Evidence-Retrieved Rate = 63.57%.
- **Prompt-based** đóng vai trò trung gian cân bằng, đạt Token Recall = 0.7555 cao nhất trong mô hình sinh và duy trì khả năng thu hồi bằng chứng ở mức cao (Coverage = 0.7320).

6.2 RQ1: Retrieval Ranking và Early Precision

Để trả lời RQ1, chúng tôi phân tích hành vi của bộ dense retrieval khi xếp hạng các ứng viên ban đầu. Kết quả thực nghiệm bộc lộ một sự phân hóa

Strategy	Retrieval & Ranking				Evidence Recovery		Answer Generation Quality		
	Hit@1	Hit@10	MRR	Recall@10	Coverage	AER (%)	Precision	Recall	Token F1
Fixed-size	0.8071	0.9643	0.8732	0.9429	0.6905	57.14%	0.2858	0.7420	0.3830
Structure-aware	<u>0.7786</u>	1.0000	<u>0.8692</u>	0.9857	0.7476	63.57%	<u>0.2798</u>	0.7398	<u>0.3766</u>
Prompt-based	0.7571	<u>0.9857</u>	0.8508	<u>0.9786</u>	<u>0.7320</u>	<u>61.43%</u>	0.2707	0.7555	0.3721

Table 3: Tổng hợp kết quả thực nghiệm so sánh ba chiến lược chunking trên 140 câu hỏi benchmark dưới cùng retrieval token budget (2.048 tokens). Số liệu in đậm thể hiện kết quả tốt nhất (**best performance**), số liệu gạch chân thể hiện kết quả tốt thứ nhì (second-best).

sâu sắc giữa early precision ở thứ hạng đầu và deep candidate recall ở các thứ hạng sâu.

Ưu thế xếp hạng sớm của Fixed-size. Chiến lược Fixed-size đạt Hit@1 = 0.8071, vượt trội hơn hẳn so với Structure-aware (0.7786, chênh lệch +0.0285 tuyệt đối) và Prompt-based (0.7571, chênh lệch +0.0500 tuyệt đối). Về chỉ số MRR, Fixed-size cũng giữ vị trí số một với 0.8732 so với 0.8692 của Structure-aware và 0.8508 của Prompt-based. Nguyên nhân bắt nguồn từ đặc tính kích thước chunk:

- Các chunk Fixed-size có độ dài trung bình lớn nhất (447.1 tokens, tập trung dày đặc ở ngưỡng trần 512 tokens), kết hợp với cơ chế sliding-window overlap 64 tokens (11.22% redundancy, tương ứng 58.623 token trùng lặp). Kích thước lớn này cho phép một chunk bao hàm đồng thời nhiều từ khóa và ngữ cảnh đồng xuất hiện trong câu truy vấn của người dùng.
- Khi mô hình embedding (text-embedding-3-small) nén thông tin, chunk có mật độ từ khóa phong phú và ngữ cảnh rộng sẽ tạo ra vector biểu diễn có Cosine similarity vượt trội với câu hỏi, giúp đẩy chunk này lên vị trí xếp hạng $r = 1$ một cách ổn định.

Sự bứt phá của Structure-aware ở thứ hạng sâu. Ngược lại, khi mở rộng phạm vi ứng viên sang Top-5 và Top-10, Structure-aware nhanh chóng vượt lên dẫn đầu:

- Ở chỉ số Hit@5, cả Structure-aware và Prompt-based đều đạt 0.9786, vượt qua Fixed-size (0.9643).
- Ở chỉ số Hit@10, Structure-aware đạt tỷ lệ hoàn hảo 1.0000 (140/140 câu hỏi đều tìm thấy ít nhất một nguồn tài liệu liên quan trong Top-10), so với 0.9857 của Prompt-based và 0.9643 của Fixed-size.

- Về Recall@10, Structure-aware thu hồi được 98.57% tổng số tài liệu nguồn liên quan, vượt trội so với Prompt-based (97.86%) và Fixed-size (94.29%).

Cơ chế đằng sau hiện tượng này là việc bảo toàn ranh giới heading hierarchy và khối nguyên tử của AST parser. Nhờ non-coalescing sibling constraint, Structure-aware tránh được hiện tượng semantic dilution. Các section nhỏ mang nội dung chuyên biệt cao không bị hòa tan vào các khối văn bản lớn, giúp vector index dễ dàng nhận diện và nâng các đoạn tài liệu thứ cấp nhưng quan trọng vào Top-10 ứng viên.

6.3 RQ2: Khả năng Thu hồi Bằng chứng trong Ngân sách Token (Evidence Recovery)

RQ2 khảo sát năng lực thu hồi các đơn vị gold evidence ($\mathcal{E}^*$) dưới ràng buộc nghiêm ngặt của retrieval token budget ($B = 2.048$ tokens). Đây là thước đo mang tính quyết định đối với các hệ thống RAG thực tế, bởi vì mô hình sinh luôn bị giới hạn bởi context window và chi phí tính toán.

Sự vượt trội của Structure-aware. Đối với 233 đơn vị gold evidence được trích xuất độc lập, Structure-aware thể hiện ưu thế vượt trội:

- **Evidence Coverage:** Structure-aware đạt 0.7476 (74.76%), cao hơn rõ rệt so với Prompt-based (73.20%) và bỏ xa Fixed-size (69.05%, chênh lệch +5.71% tuyệt đối).
- **All-Evidence-Retrieved Rate (AER):** Đối với các câu hỏi phức tạp đòi hỏi thu hồi đầy đủ 100% các bằng chứng rải rác, Structure-aware đạt tỷ lệ 63.57%, cao hơn Prompt-based (61.43%) và vượt trội so với Fixed-size (57.14%, chênh lệch +6.43% tuyệt đối).

Cơ chế tối ưu hóa budget packing. Ưu thế thu hồi bằng chứng của Structure-aware được giải thích trực tiếp thông qua động học đóng gói token (budget packing efficiency):

Strategy	Chunks	Raw Tokens	Utilization	Overhead
Fixed-size	4.94	2016.6	98.47%	27.1
Structure-aware	14.64	2039.3	99.57%	75.5
Prompt-based	8.62	2027.0	98.97%	37.8

Table 4: Đặc tính ngữ cảnh trung bình mỗi câu hỏi dưới retrieval token budget 2.048 tokens.

- Do kích thước trung bình của các chunk Structure-aware nhỏ và hạt mịn (165.1 tokens so với 447.1 tokens của Fixed-size), thuật toán greedy accumulator có thể chọn trung bình 14.64 chunks cho mỗi câu hỏi, gấp gần 3 lần so với 4.94 chunks của Fixed-size (Bảng 4).
- Kích thước hạt mịn giúp Structure-aware khai thác tới 99.57% dung lượng ngân sách 2.048 tokens (2039.3 raw tokens), dung lượng lãng phí trung bình chỉ là 8.7 tokens. Ngược lại, Fixed-size để lãng phí trung bình 31.4 tokens (2016.6 raw tokens, hiệu suất 98.47%) do các chunk 512 tokens quá lớn không thể nhồi vừa vào khoảng trống còn lại ở cuối ngân sách. Prompt-based đạt mức sử dụng 2027.0 raw tokens (98.97%) với 21.0 tokens dư thừa.
- Việc chọn được nhiều chunk độc lập cho phép bộ chọn lọc vươn sâu hơn vào danh sách ứng viên (thứ hạng tối đa trung bình được chọn là 29.37 ở Structure-aware so với 18.71 ở Prompt-based và 13.47 ở Fixed-size), giúp gom nhặt thành công các bằng chứng phân tán mà Fixed-size buộc phải bỏ sót.

6.4 RQ3: Chất lượng Câu trả lời Sinh ra (Answer Generation Fidelity)

RQ3 đánh giá tác động cuối cùng của ngữ cảnh được thu hồi lên độ chính xác của câu trả lời do gpt-5-mini sinh ra. Kết quả ở phương diện này mang lại những phát hiện bất ngờ và sâu sắc về mặt kiến trúc.

Nghịch lý chất lượng câu trả lời. Mặc dù thua kém về Evidence Coverage và Recall@10, Fixed-size lại đạt điểm số tổng thể cao nhất ở cả Token Precision (0.2858) và Token F1 (0.3830, trung vị 0.3675, khoảng tin cậy 95% bootstrap [0.3570, 0.4097]). Structure-aware đứng thứ nhì với Token F1 = 0.3766 (trung vị 0.3581, CI [0.3507, 0.4032]) và Token Precision = 0.2798. Trong khi đó, Prompt-based đạt Token Recall cao nhất (0.7555) nhưng Token Precision thấp nhất

(0.2707), dẫn đến Token F1 = 0.3721 (trung vị 0.3560, CI [0.3481, 0.3965]).

Hiện tượng Context Fragmentation. Để làm sáng tỏ nghịch lý tại sao phương pháp thu hồi nhiều bằng chứng hơn (Structure-aware) lại không mang lại điểm Token F1 cao nhất, chúng tôi phân tích cấu trúc của prompt đưa vào generator:

- **Synthesis Burden:** Để đưa được nhiều bằng chứng vào ngân sách, Structure-aware phải chia nhỏ ngữ cảnh thành trung bình 14.64 khối rời rạc, đòi hỏi 75.5 tokens phụ trợ cho các nhãn [CONTEXT n] và dấu phân cách. Ngữ cảnh bị phân mảnh cao độ buộc mô hình sinh phải thực hiện thao tác liên kết thông tin phức tạp giữa nhiều mảnh vụn, làm tăng nguy cơ bỏ sót các liên kết cú pháp tự nhiên hoặc sinh câu trả lời rườm rà.
- **Context Continuity:** Fixed-size chỉ cung cấp 4.94 khối văn bản lớn. Mặc dù có chứa một lượng gổ đầu thừa (11.22%), các chunk lớn bảo toàn được dòng chảy tự nhiên của bài viết kỹ thuật, giúp LLM dễ dàng đọc hiểu, trích xuất nguyên văn thuật ngữ và tổng hợp câu trả lời cô đọng, từ đó nâng cao Token Precision.
- **Prompt-based và độ phủ từ vựng:** Các chunk ngữ nghĩa của Prompt-based bao quát rộng các khía cạnh liên quan của câu hỏi, giúp mô hình sinh thu hồi được nhiều token của đáp án chuẩn nhất (Token Recall = 0.7555), nhưng việc diễn giải mở rộng lại làm giảm độ tập trung từ vựng (Token Precision = 0.2707).

Ý nghĩa thống kê và độ bất định. Kiểm định hoán vị có dấu (paired sign-flip permutation tests với 100.000 lượt mô phỏng, hiệu chỉnh Holm-Bonferroni ở $\alpha = 0.05$) xác nhận rằng sự chênh lệch điểm số Token F1 giữa ba phương pháp không đạt mức có ý nghĩa thống kê:

- Fixed-size so với Structure-aware: $\Delta = +0.0064$, khoảng tin cậy 95% bootstrap $[-0.0114, 0.0235]$, $p = 0.9585$.
- Fixed-size so với Prompt-based: $\Delta = +0.0108$, khoảng tin cậy 95% bootstrap $[-0.0083, 0.0301]$, $p = 0.8260$.
- Structure-aware so với Prompt-based: $\Delta = +0.0045$, khoảng tin cậy 95% bootstrap $[-0.0159, 0.0262]$, $p = 0.9585$.

Difficulty	Count	Fixed-size	Structure-aware	Prompt-based
Easy	60	0.3892	<u>0.3831</u>	0.3723
Medium	40	<u>0.3863</u>	0.3862	0.3939
Hard	40	0.3702	<u>0.3571</u>	0.3501
Overall	140	0.3830	<u>0.3766</u>	0.3721

Table 5: Hiệu năng Token F1 phân tầng theo question difficulty.

Mọi khoảng tin cậy đều bao hàm giá trị 0. Phân tích độ ổn định xếp hạng bootstrap (bootstrap ranking stability qua 50.000 mẫu lặp) cho thấy Fixed-size đạt điểm F1 trung bình cao nhất trong 68.7% số lần lấy mẫu, Structure-aware dẫn đầu trong 20.9% và Prompt-based trong 10.4%. Kết quả này chứng minh rằng việc bảo toàn cấu trúc văn bản dù đem lại lợi ích rõ rệt ở tầng retrieval nhưng chưa tạo ra bước nhảy vọt có ý nghĩa thống kê ở tầng downstream generation đối với mô hình gpt-5-mini.

6.5 Phân tích Hiệu năng theo Độ khó của Câu hỏi (Breakdown by Question Difficulty)

Để tìm hiểu sâu hơn các tình huống mà từng chiến lược phát huy thế mạnh, chúng tôi phân rã kết quả theo ba mức độ khó của 140 câu hỏi benchmark trong Bảng 5.

Nhóm Easy (60 câu – Single-section). Bằng chứng của nhóm câu hỏi này nằm trọn vẹn trong một section duy nhất của tài liệu. Fixed-size đạt Token F1 cao nhất (0.3892), xếp trên Structure-aware (0.3831) và Prompt-based (0.3723). Trong tình huống đơn section, ưu thế của chunk 512 tokens phát huy tối đa: toàn bộ câu hỏi và câu trả lời đều nằm gọn trong một chunk lớn duy nhất, giúp mô hình sinh nắm bắt toàn vẹn ngữ cảnh xung quanh mà không phải ghép nối thông tin.

Nhóm Medium (40 câu – Cross-section). Các câu hỏi này đòi hỏi tổng hợp thông tin rải rác giữa các section khác nhau trong cùng một tài liệu Angular. Ở nhóm này, Prompt-based vươn lên dẫn đầu với Token F1 = 0.3939, vượt qua Fixed-size (0.3863) và Structure-aware (0.3862). Prompt-based đạt hiệu quả cao nhờ khả năng phân định ranh giới khối dựa trên ngữ nghĩa của LLM, giúp gom nhóm các phần liên quan mật thiết thành các khối kích thước vừa phải (255.1 tokens), vừa tránh được sự cắt đôi section của Fixed-size, vừa không bị phân mảnh quá mức như Structure-aware.

Nhóm Hard (40 câu – Cross-document). Đây là nhóm thử thách nhất khi bằng chứng nằm rải rác trên nhiều tài liệu kỹ thuật hoàn toàn độc lập. Hiệu năng của tất cả các phương pháp đều sụt giảm đáng kể. Tuy nhiên, Fixed-size duy trì sự ổn định tốt nhất với Token F1 = 0.3702, tạo khoảng cách vượt trội so với Structure-aware (0.3571, chênh lệch $\Delta = +0.0131$) và Prompt-based (0.3501, chênh lệch $\Delta = +0.0201$). Khi phải truy xuất qua nhiều tài liệu khác nhau, các chunk cực nhỏ của Structure-aware đưa vào một lượng lớn các đoạn tài liệu ngoại lai (distractors), gây quá tải cho bộ nhớ ngữ cảnh của generator. Trong khi đó, các chunk lớn của Fixed-size giữ vững các khối tri thức cô đọng của từng tài liệu, hạn chế sự nhiễu loạn thông tin chéo.

6.6 Mối tương quan giữa Evidence Retrieval và Answer F1

Một câu hỏi mang tính nền tảng trong nghiên cứu RAG là: *Liệu việc thu hồi trọn vẹn 100% bằng chứng chuẩn (All-Evidence-Retrieved) có đảm bảo sinh ra câu trả lời có Token F1 cao nhất hay không?*

Hệ số tương quan thứ hạng Spearman. Phân tích tương quan phi tham số giữa Evidence Coverage và Token F1 trên 140 câu hỏi cho thấy mối quan hệ đồng biến nhưng ở mức độ yếu:

- Fixed-size: $\rho = 0.162$.
- Structure-aware: $\rho = 0.123$.
- Prompt-based: $\rho = 0.135$.

Các hệ số tương quan thấp này phản ánh sự thiếu nhất quán giữa tầng truy xuất và tầng sinh câu trả lời. Mặc dù việc thu hồi trọn vẹn toàn bộ bằng chứng mang lại điểm số F1 trung bình cao hơn trên từng chiến lược riêng biệt (mức tăng Token F1 khi đạt AER là +0.059 ở Fixed-size, +0.040 ở Structure-aware và +0.032 ở Prompt-based), nhưng ở cấp độ toàn hệ thống, chiến lược có tỷ lệ thu hồi bằng chứng cao nhất (Structure-aware với 63.57% AER) lại không phải là chiến lược đạt điểm Token F1 cao nhất.

Bản chất của Retrieval-Generation Disconnect. Sự không đồng nhất giữa kết quả retrieval và answer quality bắt nguồn từ ba nguyên nhân chính:

1. **Bản chất từ vựng của Token F1:** Token F1 đánh giá dựa trên sự trùng khớp từ vựng chính xác (lexical overlap) với đáp án tham chiếu.

Khi được cung cấp đầy đủ bằng chứng nhưng bị phân mảnh, mô hình ngôn ngữ có xu hướng diễn đạt lại (paraphrase) câu trả lời bằng văn phong tự nhiên thay vì trích xuất nguyên văn, dẫn đến việc bị phạt điểm Token F1 dù nội dung hoàn toàn chuẩn xác về mặt ngữ nghĩa.

2. Độ bền vững trước sự thiếu hụt cục bộ:

Các mô hình ngôn ngữ lớn như gpt-5-mini có khả năng suy luận logic rất mạnh. Khi chỉ thu hồi được 70 – 80% bằng chứng trực tiếp nhưng ngữ cảnh liền mạch (như ở Fixed-size), mô hình vẫn có thể tổng hợp thành công câu trả lời kỹ thuật chính xác.

3. Ảnh hưởng của Distractor Chunks: Để tối đa hóa số lượng bằng chứng thu hồi, Structure-aware phải đưa vào tới 14.64 chunks, vô tình kéo theo các đoạn văn bản có độ tương đồng thấp hơn ở các thứ hạng sâu ($r > 10$). Những đoạn này hoạt động như các yếu tố gây nhiễu, làm giảm độ tập trung của cơ chế chú ý (attention mechanism) trong LLM.

Tóm lại, kết quả thực nghiệm chỉ ra rằng việc tối ưu hóa độ tập trung ranh giới chunk ở tầng retrieval không thể tự động giải quyết bài toán chất lượng RAG; một chiến lược chunking tối ưu phải là sự dung hòa giữa độ phủ bằng chứng và tính liền mạch của cấu trúc ngữ cảnh nạp vào mô hình sinh.

7 Thảo luận

Các phát hiện thực nghiệm được trình bày tại Mục 6 đã bộc lộ những góc nhìn sâu sắc và có phần phi trực giác về vai trò của chunking strategy trong chu trình RAG. Trái với giả định phổ biến rằng các phương pháp phân đoạn bảo toàn cấu trúc hoặc ứng dụng mô hình ngôn ngữ lớn sẽ mang lại ưu thế áp đảo toàn diện, dữ liệu kiểm toán thực tế chứng minh sự tồn tại của các mối quan hệ trade-off phức tạp giữa tầng truy xuất và tầng sinh câu trả lời. Chương này mổ xẻ các cơ chế bản chất đằng sau các hiện tượng thực nghiệm và đề xuất các nguyên tắc định hình kiến trúc cho hệ thống RAG thực tế.

7.1 Sự Đánh Đổi giữa Early Ranking và Evidence Recovery

Một trong những phát hiện nổi bật nhất của nghiên cứu là sự phân hóa rõ rệt giữa năng lực xếp hạng sớm (early ranking) và khả năng thu hồi bằng

chứng chuẩn (evidence recovery) dưới cùng một retrieval token budget cố định (2.048 tokens).

Mật độ ngữ nghĩa cục bộ và ưu thế của Fixed-size. Chiến lược Fixed-size chiếm vị trí quán quân ở các chỉ số xếp hạng đầu với Hit@1 = 0.8071 và MRR = 0.8732 (Bảng 3). Ưu thế này bắt nguồn trực tiếp từ cấu trúc vật lý của chunk:

- Với kích thước lớn (trung bình 447.1 tokens, tập trung dày đặc ở ngưỡng trần 512 tokens) kết hợp cùng sliding-window overlap 64 tokens, chunk Fixed-size hình thành một vùng mật độ ngữ nghĩa cục bộ dày đặc (high local semantic density). Không gian này bảo tồn đồng thời nhiều thực thể, từ khóa và câu văn bổ trợ xung quanh.
- Khi mô hình dense embedding (text-embedding-3-small) ánh xạ đoạn văn bản vào không gian vector, chunk lớn mang đầy đủ tín hiệu ngữ cảnh để khớp với câu hỏi độc lập của người dùng, giúp vector tương đồng Cosine đạt giá trị cực đại và đẩy chunk lên vị trí $r = 1$ một cách vững chắc.
- Tuy nhiên, cái giá phải trả của Fixed-size là sự dư thừa thông tin nghiêm trọng: toàn bộ kho ngữ liệu phát sinh tới 58.623 token trùng lặp do trượt gối đầu (11.22% redundancy). Khi đưa vào bộ nạp context budget 2.048 tokens, các chunk chồng kênh khiến thuật toán greedy accumulator chỉ có thể chọn trung bình 4.94 chunks mỗi truy vấn (Bảng 4), vượt tới thứ hạng tối đa khiếm tốn là 13.47 và lãng phí 31.4 tokens chưa sử dụng. Hệ quả là Fixed-size bỏ sót nhiều đơn vị bằng chứng nằm phân tán, chỉ đạt Evidence Coverage 69.05% và All-Evidence-Retrieved Rate (AER) 57.14%.

Đóng gói tối ưu và sức mạnh thu hồi của Structure-aware. Ngược lại hoàn toàn với Fixed-size, Structure-aware tuân thủ chặt chẽ ranh giới heading hierarchy của tài liệu Markdown và áp dụng chính sách non-coalescing sibling constraint. Chiến lược này tạo ra các khối văn bản hạt mịn (trung bình 165.1 tokens) với 0% trùng lặp nội dung:

- Do diện tích bề mặt từ vựng của từng block nhỏ hơn, điểm Cosine similarity của một chunk Structure-aware đơn lẻ có thể thấp hơn khi so sánh với một khối văn bản đồ sộ 512 tokens, khiến Hit@1 dừng lại ở 0.7786.

- Tuy nhiên, khi vận hành dưới giới hạn retrieval token budget, kích thước hạt mịn giải phóng sức mạnh vượt trội cho thuật toán greedy accumulator: hệ thống có thể nhồi trung bình tới 14.64 chunks độc lập vào context window mà vẫn tận dụng tới 99.57% dung lượng ngân sách (lãng phí vốn vẹn 8.7 tokens).
- Khả năng vướn sâu vào danh sách ứng viên (thứ hạng tối đa trung bình đạt 29.37) cho phép Structure-aware thu gom triệt để các mảnh ghép bằng chứng nằm rải rác ở các section xa xôi, thiết lập kỷ lục $\text{Hit@10} = 1.0000$, $\text{Recall@10} = 0.9857$, $\text{Evidence Coverage} = 0.7476$ và $\text{AER} = 63.57\%$.

Như vậy, một sự đánh đổi kiến trúc cơ bản đã được xác lập: *Fixed-size tối ưu hóa cho độ chuẩn xác của ứng viên đơn lẻ ở đỉnh danh mục ($r = 1$), trong khi Structure-aware tối ưu hóa độ bao phủ thông tin đa chiều trên toàn bộ ngân sách ngữ cảnh.*

7.2 Nghịch Lý Phân Mảnh Ngữ Cảnh và Gánh Nặng Tổng Hợp

Mặc dù Structure-aware vượt trội ở mọi chỉ số thu hồi bằng chứng, kết quả downstream generation lại mang đến một nghịch lý rõ rệt: Fixed-size mới là chiến lược dẫn đầu về Token F1 tổng thể (0.3830 so với 0.3766) và Token Precision (0.2858 so với 0.2798). Hiện tượng này phơi bày hai rào cản kỹ thuật quan trọng ở giao diện giữa retrieval và generation: hiện tượng Context Fragmentation và gánh nặng tổng hợp (Synthesis Burden).

Bản chất của hiện tượng Context Fragmentation. Khi nạp trung bình 14.64 chunks rời rạc từ Structure-aware vào prompt của downstream generator (gpt-5-mini), ngữ cảnh kỹ thuật bị xé nhỏ thành các mảnh vụn biệt lập (fragmented snippets). Quá trình này gây ra hai hệ lụy nghiêm trọng:

1. **Tiêu hao token phụ trợ (Overhead Cost):** Việc duy trì 14.64 khối độc lập đòi hỏi bộ tiền xử lý phải chèn các nhãn phân đoạn [CONTEXT n] và dấu ngắt dòng liên tục, tiêu tốn trung bình 75.5 tokens phụ trợ cho mỗi truy vấn (gấp gần 3 lần mức 27.1 tokens của Fixed-size). Lượng token định dạng này chiếm dụng không gian lẽ ra có thể dùng để chứa nội dung tri thức hữu ích.

2. **Đứt gãy dòng chảy diễn ngôn (Discourse Discontinuity):** Tài liệu kỹ thuật đòi hỏi tính liền mạch cao độ giữa định nghĩa khái niệm, đoạn mã minh họa và các chú giải điều kiện biên. Khi bị phân rã theo cấu trúc heading, các câu văn dẫn dắt và mối quan hệ tiền đề-hệ quả bị cắt rời, làm mất đi tính toàn vẹn ngữ cảnh tự nhiên.

Gánh nặng tổng hợp đặt lên Downstream Generator. Ngữ cảnh phân mảnh đặt một áp lực tính toán rất lớn lên cơ chế chú ý (attention mechanism) của mô hình sinh. LLM buộc phải thực hiện thao tác giải quyết đồng tham chiếu (coreference resolution) phức tạp giữa các mảnh ghép không cùng dòng chảy, đồng thời phải tự chấp vá các mệnh đề logic bị gián đoạn. Hơn nữa, do Structure-aware vướn sâu tới thứ hạng 29.37, xác suất đưa vào các đoạn văn bản ngoại lai (distractor chunks) gia tăng đáng kể, gây nhiễu loạn bộ nhớ ngữ cảnh của mô hình.

Ngược lại, context của Fixed-size chỉ bao gồm 4.94 khối văn bản lớn. Dù thu hồi ít bằng chứng thứ cấp hơn, các khối này bảo toàn nguyên vẹn dòng chảy văn bản, chứa đầy đủ các câu định nghĩa và thuật ngữ đi kèm. Nhờ đó, downstream generator dễ dàng nhận diện từ khóa then chốt, trích xuất nguyên văn thuật ngữ kỹ thuật và sinh ra câu trả lời cô đọng, đạt Token Precision cao hơn hẳn.

Đặc thù từ vựng của độ đo Token F1. Cần nhấn mạnh rằng Token F1 là một độ đo thuần túy dựa trên sự trùng khớp từ vựng (lexical overlap). Khi đối mặt với ngữ cảnh bị phân mảnh cao, mô hình ngôn ngữ lớn có xu hướng diễn giải lại (paraphrase) câu trả lời bằng văn phong tự nhiên thay vì sao chép nguyên văn câu chữ của tài liệu nguồn. Hành vi này khiến mô hình bị phạt điểm Token F1 dù nội dung hoàn toàn chuẩn xác về mặt ngữ nghĩa kỹ thuật. Đây chính là yếu tố giải thích tại sao mức tương quan Spearman giữa Evidence Coverage và Token F1 lại ở mức thấp ($\rho = 0.123 - 0.162$, Mục 6.6).

7.3 Đánh Giá Tính Khả Thi của Prompt-Based Chunking

Phương pháp Prompt-based (sử dụng artifact đồng bằng prompt_based_v1) đại diện cho hướng tiếp cận hiện đại sử dụng chính mô hình ngôn ngữ lớn để nhận diện ranh giới ngữ nghĩa của văn bản. Mặc dù sở hữu những đặc tính lý thuyết hấp dẫn, phân tích thực nghiệm chứng minh rằng phương pháp này không đạt được vị thế tối ưu Pareto

(Pareto optimality) trong bối cảnh ứng dụng thực tế.

Hiệu năng downstream không tương xứng.

Trên phương diện chất lượng văn bản, Prompt-based đạt tỷ lệ bảo toàn bằng chứng đơn khối cao nhất (99.6% đơn vị gold evidence được chứa trọn trong duy nhất một chunk) và giúp downstream generator đạt Token Recall cao nhất (0.7555). Tuy nhiên, khả năng thu hồi từ vụng này không chuyển hóa thành thắng lợi ở điểm số tổng hợp: Token F1 của Prompt-based chỉ đạt 0.3721 (thấp nhất trong ba phương pháp), trong khi Token Precision tụt dốc xuống 0.2707 do câu trả lời có xu hướng dàn trải và thiếu tập trung. Ở tầng retrieval, các chỉ số của Prompt-based ($\text{Hit@1} = 0.7571$, $\text{MRR} = 0.8508$) đều nằm ở vị trí cuối cùng.

Rào cản chi phí và độ phức tạp vận hành. Về mặt kỹ thuật hệ thống, Prompt-based bộc lộ những hạn chế cố hữu:

- **Chi phí suy luận và độ trễ tiền xử lý (Indexing Latency):** Để phân đoạn kho ngữ liệu 384 tài liệu Markdown, hệ thống phải thực hiện hàng trăm lượt gọi API đến LLM với chi phí tài chính đáng kể và rủi ro nghẽn giới hạn tần suất (rate limits). Độ trễ giai đoạn offline indexing tăng lên gấp nhiều lần so với các giải pháp chạy cục bộ.
- **Độ bất tất định (Non-determinism):** Dù có kiểm soát prompt nghiêm ngặt, ranh giới phân đoạn của LLM vẫn tiềm ẩn sự trôi dạt ngữ nghĩa giữa các phiên bản mô hình, đòi hỏi các quy trình kiểm duyệt và xác thực artifact tốn kém.

Khi đặt cạnh Structure-aware—một giải pháp dựa trên bộ phân tích cú pháp AST cục bộ với chi phí suy luận bằng 0, tốc độ thực thi tính bằng mili-giây và khả năng tái lập tất định 100%—việc triển khai Prompt-based cho giai đoạn chunking rõ ràng mang lại tỷ suất hoàn vốn kỹ thuật (return on engineering investment) rất thấp.

7.4 Khuyến Nghị Lựa Chọn Kiến Trúc cho Hệ Thống RAG

Từ những phân tích định lượng và cơ chế trade-off đã làm sáng tỏ, chúng tôi đề xuất các chỉ dẫn kỹ thuật cụ thể nhằm định hướng việc lựa chọn và thiết kế kiến trúc RAG trên tài liệu kỹ thuật:

Trường hợp ưu tiên lựa chọn Fixed-size. Chiến lược Fixed-size (với sliding-window overlap vừa phải) là sự lựa chọn tối ưu trong các kịch bản:

1. **Hệ thống QA dạng Factoid và tra cứu định nghĩa:** Đối với các câu hỏi đơn giản (phân nhóm Easy tại Bảng 5 nơi Fixed-size đạt $\text{Token F1} = 0.3892$), câu trả lời thường tập trung trọn vẹn trong một đoạn văn bản duy nhất.
2. **Hệ thống đòi hỏi độ trễ cực thấp (Low Latency):** Nhờ số lượng chunk ít (4.94 blocks) và định dạng gọn gàng, độ dài prompt nạp vào LLM được tối giản, giúp tăng tốc độ sinh từ đầu tiên (Time-to-First-Token) và tiết kiệm chi phí token đầu vào.
3. **Ưu tiên độ chính xác tuyệt đối ở Top-1:** Các ứng dụng tra cứu nhanh nơi người dùng chỉ quan tâm đến đoạn trích dẫn đầu tiên hiển thị trên giao diện người dùng.

Trường hợp bắt buộc lựa chọn Structure-aware. Chiến lược Structure-aware là yêu cầu bắt buộc đối với các môi trường nghiệp vụ mang tính sống còn:

1. **Hệ thống kiểm toán tuân thủ (Compliance Audit) và tài liệu API:** Trong các bài toán kỹ thuật phức tạp đòi hỏi phải thu thập đầy đủ mọi điều kiện tiên quyết và cảnh báo an toàn rải rác qua nhiều module, chỉ số All-Evidence-Retrieved Rate (63.57%) của Structure-aware là yếu tố quyết định để ngăn chặn việc đưa ra hướng dẫn sai lệch.
2. **Hệ thống có ràng buộc chặt về ngân sách token:** Khi tài nguyên context budget bị bóp nghẹt, khả năng khai thác tới 99.57% dung lượng ngân sách của Structure-aware giúp tối đa hóa mật độ thông tin nạp vào bộ xử lý.

Định hướng kiến trúc lai trong tương lai (Hybrid Outlook). Để giải quyết triệt để sự mâu thuẫn giữa độ bao phủ bằng chứng của Structure-aware và tính liền mạch ngữ cảnh của Fixed-size, chúng tôi khuyến nghị hai hướng cải tiến kiến trúc:

- **Parent-Document Retrieval (Hierarchical Indexing):** Sử dụng các đơn vị AST nhỏ của Structure-aware làm vector khóa để tìm kiếm ở tầng retrieval nhằm tối đa hóa độ nhạy khớp

lệnh, nhưng khi nạp vào context cho downstream generator thì tự động mở rộng và truy hồi toàn bộ section cha (parent section) tương ứng.

- **Hợp nhất Chunk động (Dynamic Chunk Merging):** Thiết lập cơ chế hậu xử lý context sau khi retrieval: nếu hai hoặc nhiều chunk liên tiếp được chọn thuộc về cùng một văn bản nguồn hoặc cùng một nhánh tiêu đề đồng cấp, hệ thống sẽ tự động gộp chúng thành một khối duy nhất trước khi đánh số nhân [CONTEXT n]. Cơ chế này sẽ loại bỏ hoàn toàn hiện tượng Context Fragmentation, cắt giảm triệt để overhead token và giảm thiểu gánh nặng tổng hợp cho mô hình ngôn ngữ lớn.

8 Hạn chế của Nghiên cứu

Mặc dù quy trình thực nghiệm được thiết kế và kiểm toán nghiêm ngặt theo các tiêu chuẩn đóng băng dữ liệu (benchmark freeze), công trình này vẫn tồn tại một số giới hạn phương pháp luận cần được nhìn nhận một cách khách quan nhằm định hướng cho các nghiên cứu tiếp theo:

Phạm vi dữ liệu và ngôn ngữ (Corpus & Language Scope). Toàn bộ thực nghiệm trong nghiên cứu này được tiến hành độc quyền trên kho tài liệu kỹ thuật của framework Angular bằng tiếng Anh, có cấu trúc cú pháp định dạng chuẩn Markdown. Do đó, các kết luận thực nghiệm không tự động suy diễn (generalize) cho các thể loại tài liệu phi cấu trúc khác (như văn bản tự do, tệp PDF đã qua xử lý OCR, báo cáo tài chính hay slide trình chiếu), cũng như các hệ thống tài liệu kỹ thuật đa ngôn ngữ. Cấu trúc phân cấp tiêu đề (heading hierarchy) và các khối cú pháp code block của Markdown có thể tạo ra những tương tác đặc thù với bộ phân tích cú pháp AST mà các định dạng tài liệu khác không sở hữu.

Độ bao phủ của Benchmark (Benchmark Coverage). Mặc dù kho ngữ liệu gốc bao gồm 384 tài liệu Markdown hoàn chỉnh, bộ benchmark đóng băng 140 cặp câu hỏi QA và 233 đơn vị gold evidence hiện tại mới chỉ khai thác và neo giữ bằng chứng trên 55 tài liệu nguồn được chọn lọc. Bên cạnh đó, dù 140 câu hỏi được phân bổ cân bằng trên 3 phân tầng độ khó chính (60 Easy, 40 Medium, 40 Hard), một số phân nhóm câu hỏi nhỏ theo dạng thức kỹ thuật sâu (question-type strata như cú pháp syntax với $n = 1$, cơ chế bảo mật security_mechanism với $n = 1$, hay nguyên nhân-

hệ quả cause_effect với $n = 2$) có kích thước mẫu quá nhỏ. Các kết quả trên những nhóm này thuần túy mang tính mô tả khám phá và chưa đủ lực thống kê để khái quát hóa thành kết luận độc lập.

Cấu hình pipeline và ngân sách đơn lẻ (Single-Configuration Pipeline). Nghiên cứu áp dụng thiết kế thực nghiệm kiểm soát nhằm cô lập tác động thuần túy của chunking strategy, do đó đã cố định một cấu hình duy nhất: một mô hình dense embedding (text-embedding-3-small), một mô hình sinh câu trả lời (gpt-5-mini), một độ sâu danh sách ứng viên ($k = 50$), một ngưỡng retrieval token budget (2.048 tokens) và một mức context budget (4.096 tokens). Nghiên cứu chưa thực hiện kiểm thử lưới đa ngân sách (multi-budget grid search, ví dụ 1.024 hay 4.096 tokens), chưa tích hợp tăng tái xếp hạng học máy (cross-encoder reranker), và chưa khảo sát sự tương tác của các chiến lược phân đoạn với các kiến trúc mô hình ngôn ngữ lớn khác (như Claude, Gemini hay các mô hình open-weight như Llama).

Phương pháp đánh giá câu trả lời (Answer Evaluation Scope). Chất lượng câu trả lời sinh ra hiện được đo lường thông qua các chỉ số trùng khớp từ vựng cấp độ token (Token Precision, Token Recall, Token F1) đối chiếu với câu trả lời chuẩn tắc của chuyên gia sau khi chuẩn hóa Unicode NFKC. Dù phương pháp này đảm bảo tính tất định và khả năng tái lập độc lập 100%, bản chất từ vựng của Token F1 có thể đánh giá chưa thỏa đáng các trường hợp mô hình diễn giải lại (paraphrase) câu trả lời bằng văn phong tự nhiên mà vẫn đảm bảo tính chính xác tuyệt đối về mặt kỹ thuật. Nghiên cứu chưa mở rộng sang việc áp dụng các khung đánh giá ngữ nghĩa đa chiều như LLM-as-a-judge có đối chứng hoặc human evaluation trên quy mô lớn.

Giới hạn của Prompt-Based Chunking Artifact. Chiến lược phân đoạn dựa trên prompt trong nghiên cứu này sử dụng dữ liệu được trích xuất từ artifact lịch sử cố định (prompt_based_v1) theo cam kết của phiên bản benchmark đóng băng v2. Nghiên cứu chưa khảo sát việc tối ưu hóa prompt động (dynamic prompt tuning), cung cấp ví dụ mẫu theo ngữ cảnh (few-shot in-context demonstrations) hay huấn luyện mô hình phân đoạn chuyên biệt (dedicated chunker fine-tuning). Do đó, kết quả của Prompt-based trong báo cáo phản ánh hiệu năng của artifact cụ thể này chứ không

đại diện cho giới hạn tối đa của hướng tiếp cận prompt-based nói chung.

9 Kết luận

Nghiên cứu này đã thực hiện một cuộc đánh giá thực nghiệm toàn diện, nghiêm ngặt và có khả năng tái lập độc lập 100% nhằm làm sáng tỏ tác động thực sự của ba chiến lược chunking—Fixed-size, Structure-aware và Prompt-based—lên toàn bộ chu trình RAG trên tài liệu kỹ thuật Mark-down. Dưới thiết kế kiểm soát chặt chẽ với cùng một kho ngữ liệu Angular 384 tài liệu, cùng một mô hình embedding và generator, cùng giới hạn nghiêm ngặt của retrieval token budget 2.048 tokens và context budget 4.096 tokens, công trình đã giải đáp dứt khoát ba câu hỏi nghiên cứu cốt lõi:

- **RQ1 (Retrieval Ranking và Early Precision):** Chiến lược Fixed-size chiếm ưu thế tuyệt đối ở các thứ hạng sớm với Hit@1 = 0.8071 và MRR = 0.8732 nhờ kích thước chunk lớn (447.1 tokens) và cơ chế sliding-window overlap 64 tokens tạo ra mật độ ngữ nghĩa cục bộ dày đặc. Tuy nhiên, khi mở rộng phạm vi ứng viên, Structure-aware nhanh chóng bắt phá và xác lập kỷ lục dẫn đầu với Hit@10 = 1.0000 và Recall@10 = 0.9857 nhờ việc tôn trọng ranh giới heading hierarchy của AST parser và ngăn ngừa hiện tượng semantic dilution.
- **RQ2 (Khả năng Thu hồi Bằng chứng trong Ngân sách Token):** Dưới giới hạn retrieval token budget 2.048 tokens, Structure-aware thể hiện sức mạnh áp đảo toàn diện với Evidence Coverage = 0.7476 (74.76%) và All-Evidence-Retrieved Rate = 63.57%, vượt xa Fixed-size (69.05% và 57.14%). Khả năng đóng gói token tối ưu (budget packing efficiency đạt 99.57%) cho phép thuật toán greedy accumulator nhồi trung bình 14.64 chunks hạt mịn độc lập vào context window mà không lãng phí tài nguyên vào phần văn bản trùng lặp thừa thãi.
- **RQ3 (Chất lượng Câu trả lời Sinh ra):** Fixed-size dẫn đầu về tổng thể Answer Token F1 (0.3830) và Token Precision (0.2858) do cung cấp ít khối văn bản hơn (4.94 chunks), bảo tồn dòng chảy diễn ngôn liền mạch và giảm thiểu gánh nặng tổng hợp (synthesis burden) cho downstream generator (gpt-5-mini); trong khi Prompt-based đạt Token Re-

call cao nhất (0.7555). Dù vậy, các kiểm định hoán vị có dấu (paired sign-flip permutation tests, Holm-adjusted $p > 0.82$) xác nhận rằng sự chênh lệch Token F1 giữa ba phương pháp chưa đạt mức có ý nghĩa thống kê, chứng minh rằng ưu thế thu hồi bằng chứng ở tầng retrieval không tự động chuyển hóa thành bước nhảy vọt ở tầng downstream generation.

Thông điệp cốt lõi được đúc kết từ công trình này là: *Không tồn tại một chiến lược chunking tối ưu vạn năng cho mọi hệ thống RAG (no one-size-fits-all)*. Quyết định lựa chọn kiến trúc phải căn cứ chặt chẽ vào mục tiêu nghiệp vụ cụ thể: các kỹ sư RAG nên lựa chọn **Fixed-size** khi xây dựng các ứng dụng factoid QA hoặc tra cứu định nghĩa đơn giản ưu tiên độ trễ cực thấp và độ chuẩn xác ở Top-1; và bắt buộc phải triển khai **Structure-aware** khi đối mặt với các bài toán kiểm toán tuân thủ, tài liệu API chuyên sâu hoặc tổng hợp đa bước (multi-hop reasoning) nơi việc thu hồi đầy đủ 100% bằng chứng kỹ thuật là điều kiện tiên quyết. Các phát hiện về hiện tượng Context Fragmentation trong nghiên cứu này mở ra triển vọng ứng dụng các kiến trúc lai (hybrid approaches) như Parent-Document Retrieval và Dynamic Chunk Merging nhằm dung hòa trọn vẹn giữa độ bao phủ bằng chứng của bộ parser cấu trúc và tính liền mạch ngữ cảnh cho các mô hình ngôn ngữ lớn thế hệ mới.

References

- Arihant Jain, Purav Aggarwal, and Anoop Saladi. 2025. [AutoChunker: Structured text chunking and its evaluation](#). In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics: Industry Track*, pages 983–995, Vienna, Austria. Association for Computational Linguistics.
- Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. 2020. [Retrieval-augmented generation for knowledge-intensive nlp tasks](#). In *Advances in Neural Information Processing Systems*, volume 33, pages 9459–9474.
- Renyi Qu, Ruixuan Tu, and Forrest Sheng Bao. 2025. [Is semantic chunking worth the computational cost?](#) In *Findings of the Association for Computational Linguistics: NAACL 2025*, pages 2155–2177, Albuquerque, New Mexico. Association for Computational Linguistics.
- Zhitong Wang, Cheng Gao, Chaojun Xiao, Yufei Huang, Shuzheng Si, Kangyang Luo, Yuzhuo Bai,

Wenhao Li, Tangjian Duan, Chuancheng Lv, Guoshan Lu, Gang Chen, Fanchao Qi, and Maosong Sun. 2025. [Document segmentation matters for retrieval-augmented generation](#). In *Findings of the Association for Computational Linguistics: ACL 2025*, pages 8063–8075, Vienna, Austria. Association for Computational Linguistics.

Hao Yu, Aoran Gan, Kai Zhang, Shiwei Tong, Qi Liu, and Zhaofeng Liu. 2024. [Evaluation of retrieval-augmented generation: A survey](#). *arXiv preprint arXiv:2405.07437*.